Solutions détaillées des exercices
Chapitre 5 : Réseaux à une couche pour la classification

Adapté de Bishop, Pattern Recognition and Machine Learning

Table des matières

1 Exercices du chapitre 5 **2**
1.1 Exercice 5.1 2
1.2 Exercice 5.2 2
1.3 Exercice 5.3 3
1.4 Exercice 5.4 4
1.5 Exercice 5.5 4
1.6 Exercice 5.6 5
1.7 Exercice 5.7 6
1.8 Exercice 5.8 6
1.9 Exercice 5.9 6
1.10 Exercice 5.10 7
1.11 Exercice 5.11 7
1.12 Exercice 5.12 7
1.13 Exercice 5.13 8
1.14 Exercice 5.14 9
1.15 Exercice 5.15 10
1.16 Exercice 5.16 10
1.17 Exercice 5.17 11
1.18 Exercice 5.18 11
1.19 Exercice 5.19 12
1.20 Exercice 5.20 12
1.21 Exercice 5.21 12
1.22 Exercice 5.22 13
1.23 Exercice 5.23 13
1.24 Exercice 5.24 14

Préambule

Ce document présente les solutions complètes et détaillées des exercices du chapitre 5 de l'ouvrage de Christopher M. Bishop, *Pattern Recognition and Machine Learning*. Les énoncés sont tirés du texte principal, et les solutions sont développées pas à pas en s'appuyant sur les résultats et notations du chapitre.

1 Exercices du chapitre 5

1.1 Exercice 5.1

Énoncé : Considérons un problème de classification à K classes avec un vecteur cible $\mathbf{t}$ utilisant un codage binaire 1-parmi-K. Montrer que l'espérance conditionnelle $\mathbb{E}[\mathbf{t}|\mathbf{x}]$ est donnée par la probabilité a posteriori $p(\mathcal{C}_k|\mathbf{x})$.

Solution détaillée :
Notons t_k la k-ième composante du vecteur $\mathbf{t}$. Par définition du codage 1-parmi-K, on a :

$$p(t_k = 1|\mathbf{x}) = p(\mathcal{C}_k|\mathbf{x}), \qquad p(t_k = 0|\mathbf{x}) = 1 - p(\mathcal{C}_k|\mathbf{x}).$$

L'espérance conditionnelle de t_k sachant $\mathbf{x}$ est alors :

$$\mathbb{E}[t_k|\mathbf{x}] = 1 \times p(t_k = 1|\mathbf{x}) + 0 \times p(t_k = 0|\mathbf{x}) = p(\mathcal{C}_k|\mathbf{x}).$$

Puisque cela est vrai pour chaque composante k, on a bien $\mathbb{E}[\mathbf{t}|\mathbf{x}] = \big(p(\mathcal{C}_1|\mathbf{x}), \ldots, p(\mathcal{C}_K|\mathbf{x})\big)^{\mathrm{T}}$.

1.2 Exercice 5.2

Énoncé : Soit un ensemble de points $\{\mathbf{x}_n\}$. Leur enveloppe convexe est l'ensemble des points $\mathbf{x}$ tels que $\mathbf{x} = \sum_n \alpha_n \mathbf{x}_n$ avec $\alpha_n \geq 0$ et $\sum_n \alpha_n = 1$. Considérons un second ensemble $\{\mathbf{y}_m\}$ et son enveloppe convexe. Par définition, les deux ensembles sont linéairement séparables s'il existe un vecteur $\hat{\mathbf{w}}$ et un scalaire w_0 tels que $\hat{\mathbf{w}}^{\mathrm{T}}\mathbf{x}_n + w_0 > 0$ pour tout $\mathbf{x}_n$ et $\hat{\mathbf{w}}^{\mathrm{T}}\mathbf{y}_m + w_0 < 0$ pour tout $\mathbf{y}_m$. Montrer que si leurs enveloppes convexes se coupent, les deux ensembles ne peuvent pas être linéairement séparables, et réciproquement, s'ils sont linéairement séparables, leurs enveloppes convexes ne se coupent pas.

Solution détaillée :
Supposons que les enveloppes convexes de $\{\mathbf{x}_n\}$ et $\{\mathbf{y}_m\}$ aient une intersection non vide. Alors il existe au moins un point $\mathbf{z}$ tel que :

$$\mathbf{z} = \sum_n \alpha_n \mathbf{x}_n = \sum_m \beta_m \mathbf{y}_m,$$

avec $\alpha_n \geq 0$, $\sum_n \alpha_n = 1$ et $\beta_m \geq 0$, $\sum_m \beta_m = 1$. Si les ensembles étaient linéairement séparables, il existerait $(\hat{\mathbf{w}}, w_0)$ vérifiant $\hat{\mathbf{w}}^{\mathrm{T}}\mathbf{x}_n + w_0 > 0$ et $\hat{\mathbf{w}}^{\mathrm{T}}\mathbf{y}_m + w_0 < 0$. En appliquant la combinaison convexe à $\mathbf{z}$ on obtiendrait :

$$\hat{\mathbf{w}}^{\mathrm{T}}\mathbf{z} + w_0 = \sum_n \alpha_n(\hat{\mathbf{w}}^{\mathrm{T}}\mathbf{x}_n + w_0) > 0,$$

car chaque terme est positif et les α_n sont non négatifs. Mais on aurait aussi :

$$\hat{\mathbf{w}}^{\mathrm{T}}\mathbf{z} + w_0 = \sum_m \beta_m(\hat{\mathbf{w}}^{\mathrm{T}}\mathbf{y}_m + w_0) < 0,$$

ce qui est contradictoire. Donc les ensembles ne peuvent être linéairement séparables si leurs enveloppes convexes se coupent.

Réciproquement, supposons qu'ils soient linéairement séparables et que leurs enveloppes convexes aient un point d'intersection $\mathbf{z}$. On aboutirait à la même contradiction. Ainsi, l'intersection des enveloppes convexes est nécessairement vide.

1.3 Exercice 5.3

Énoncé : Considérons la minimisation de la fonction d'erreur des moindres carrés (5.14). Supposons que tous les vecteurs cibles de l'ensemble d'apprentissage satisfont une contrainte linéaire $\mathbf{a}^{\mathrm{T}}\mathbf{t}_n + b = 0$, où $\mathbf{t}_n$ est la n-ième ligne de la matrice $\mathbf{T}$ dans (5.14). Montrer que, en conséquence, les prédictions du modèle $\mathbf{y}(\mathbf{x})$ données par la solution des moindres carrés (5.16) satisfont aussi cette contrainte, c'est-à-dire $\mathbf{a}^{\mathrm{T}}\mathbf{y}(\mathbf{x}) + b = 0$. On supposera qu'une des fonctions de base $\phi_0(\mathbf{x}) = 1$ (biais).

Solution détaillée :
La fonction d'erreur s'écrit, en explicitant le biais :

$$E_D(\widetilde{\mathbf{W}}) = \frac{1}{2}\mathrm{Tr}\left\{(\mathbf{X}\mathbf{W} + \mathbf{1}\mathbf{w}_0^{\mathrm{T}} - \mathbf{T})^{\mathrm{T}}(\mathbf{X}\mathbf{W} + \mathbf{1}\mathbf{w}_0^{\mathrm{T}} - \mathbf{T})\right\},$$

où $\mathbf{w}_0$ est le vecteur des biais et $\mathbf{1}$ un vecteur colonne de N uns. La dérivée par rapport à $\mathbf{w}_0$ donne :

$$2N\mathbf{w}_0 + 2(\mathbf{X}\mathbf{W} - \mathbf{T})^{\mathrm{T}}\mathbf{1} = 0.$$

En posant cette dérivée nulle, on obtient $\mathbf{w}_0 = \bar{\mathbf{t}} - \mathbf{W}^{\mathrm{T}}\bar{\mathbf{x}}$ avec $\bar{\mathbf{t}} = \frac{1}{N}\mathbf{T}^{\mathrm{T}}\mathbf{1}$ et $\bar{\mathbf{x}} = \frac{1}{N}\mathbf{X}^{\mathrm{T}}\mathbf{1}$. En substituant dans l'erreur, on fait apparaître les matrices centrées $\hat{\mathbf{X}} = \mathbf{X} - \overline{\mathbf{X}}$ et $\hat{\mathbf{T}} = \mathbf{T} - \overline{\mathbf{T}}$ où $\overline{\mathbf{X}} = \mathbf{1}\bar{\mathbf{x}}^{\mathrm{T}}$ et $\overline{\mathbf{T}} = \mathbf{1}\bar{\mathbf{t}}^{\mathrm{T}}$. La solution pour $\mathbf{W}$ est alors $\mathbf{W} = (\hat{\mathbf{X}}^{\mathrm{T}}\hat{\mathbf{X}})^{-1}\hat{\mathbf{X}}^{\mathrm{T}}\hat{\mathbf{T}}$.

La prédiction pour un nouveau point $\mathbf{x}^*$ est :

$$\mathbf{y}(\mathbf{x}^*) = \mathbf{W}^{\mathrm{T}}\mathbf{x}^* + \mathbf{w}_0 = \bar{\mathbf{t}} - \hat{\mathbf{T}}^{\mathrm{T}}(\hat{\mathbf{X}}^{\dagger})^{\mathrm{T}}(\mathbf{x}^* - \bar{\mathbf{x}}),$$

où $\hat{\mathbf{X}}^{\dagger}$ est la pseudo-inverse de $\hat{\mathbf{X}}$. Appliquons la contrainte $\mathbf{a}^{\mathrm{T}}\mathbf{t}_n + b = 0$ à tous les points : cela implique $\mathbf{a}^{\mathrm{T}}\bar{\mathbf{t}} = -b$ car la moyenne des $\mathbf{t}_n$ satisfait aussi la contrainte. De plus, $\mathbf{a}^{\mathrm{T}}\hat{\mathbf{T}}^{\mathrm{T}} = \mathbf{a}^{\mathrm{T}}(\mathbf{T} - \overline{\mathbf{T}})^{\mathrm{T}} = \mathbf{a}^{\mathrm{T}}\mathbf{T}^{\mathrm{T}} - \mathbf{a}^{\mathrm{T}}\overline{\mathbf{T}}^{\mathrm{T}}$. Or $\mathbf{a}^{\mathrm{T}}\mathbf{T}^{\mathrm{T}} = -b\mathbf{1}^{\mathrm{T}}$ et $\mathbf{a}^{\mathrm{T}}\overline{\mathbf{T}}^{\mathrm{T}} = \mathbf{a}^{\mathrm{T}}\mathbf{1}\bar{\mathbf{t}}^{\mathrm{T}} = N\bar{\mathbf{t}}^{\mathrm{T}}$? Attention, il faut calculer soigneusement. En fait, $\overline{\mathbf{T}} = \mathbf{1}\bar{\mathbf{t}}^{\mathrm{T}}$ donc $\overline{\mathbf{T}}^{\mathrm{T}} = \bar{\mathbf{t}}\mathbf{1}^{\mathrm{T}}$. Alors $\mathbf{a}^{\mathrm{T}}\overline{\mathbf{T}}^{\mathrm{T}} = \mathbf{a}^{\mathrm{T}}\bar{\mathbf{t}}\mathbf{1}^{\mathrm{T}} = (-b)\mathbf{1}^{\mathrm{T}}$. Donc $\mathbf{a}^{\mathrm{T}}\hat{\mathbf{T}}^{\mathrm{T}} = -b\mathbf{1}^{\mathrm{T}} - (-b)\mathbf{1}^{\mathrm{T}} = \mathbf{0}^{\mathrm{T}}$. Ainsi,

$$\mathbf{a}^{\mathrm{T}}\mathbf{y}(\mathbf{x}^*) = \mathbf{a}^{\mathrm{T}}\bar{\mathbf{t}} - \underbrace{\mathbf{a}^{\mathrm{T}}\hat{\mathbf{T}}^{\mathrm{T}}}_{=\mathbf{0}^{\mathrm{T}}}(\hat{\mathbf{X}}^{\dagger})^{\mathrm{T}}(\mathbf{x}^* - \bar{\mathbf{x}}) = \mathbf{a}^{\mathrm{T}}\bar{\mathbf{t}} = -b,$$

ce qui établit la contrainte.

1.4 Exercice 5.4

Énoncé : Étendre le résultat de l'exercice 5.3 pour montrer que si plusieurs contraintes linéaires sont satisfaites simultanément par les vecteurs cibles, alors les mêmes contraintes seront aussi satisfaites par la prédiction des moindres carrés d'un modèle linéaire.

Solution détaillée :
Considérons plusieurs contraintes linéaires simultanées de la forme $\mathbf{A}\mathbf{t}_n + \mathbf{b} = \mathbf{0}$, où $\mathbf{A}$ est une matrice et $\mathbf{b}$ un vecteur colonne, chaque ligne correspondant à une contrainte. En appliquant la même expression de $\mathbf{y}(\mathbf{x}^*)$ que dans l'exercice précédent, on a :

$$\mathbf{A}\mathbf{y}(\mathbf{x}^*) = \mathbf{A}\bar{\mathbf{t}} - \mathbf{A}\hat{\mathbf{T}}^{\mathrm{T}}(\hat{\mathbf{X}}^{\dagger})^{\mathrm{T}}(\mathbf{x}^* - \bar{\mathbf{x}}).$$

Or $\mathbf{A}\hat{\mathbf{T}}^{\mathrm{T}} = \mathbf{A}(\mathbf{T} - \overline{\mathbf{T}})^{\mathrm{T}}$. D'après les contraintes, $\mathbf{A}\mathbf{T}^{\mathrm{T}} = -\mathbf{b}\mathbf{1}^{\mathrm{T}}$ (car pour chaque point $\mathbf{A}\mathbf{t}_n = -\mathbf{b}$). De plus, $\overline{\mathbf{T}} = \mathbf{1}\bar{\mathbf{t}}^{\mathrm{T}}$ donc $\overline{\mathbf{T}}^{\mathrm{T}} = \bar{\mathbf{t}}\mathbf{1}^{\mathrm{T}}$ et $\mathbf{A}\overline{\mathbf{T}}^{\mathrm{T}} = \mathbf{A}\bar{\mathbf{t}}\mathbf{1}^{\mathrm{T}} = (-\mathbf{b})\mathbf{1}^{\mathrm{T}}$ puisque $\bar{\mathbf{t}}$ satisfait aussi la contrainte. Ainsi $\mathbf{A}\hat{\mathbf{T}}^{\mathrm{T}} = -\mathbf{b}\mathbf{1}^{\mathrm{T}} - (-\mathbf{b})\mathbf{1}^{\mathrm{T}} = \mathbf{0}$. Par conséquent,

$$\mathbf{A}\mathbf{y}(\mathbf{x}^*) = \mathbf{A}\bar{\mathbf{t}} = -\mathbf{b},$$

donc $\mathbf{A}\mathbf{y}(\mathbf{x}^*) + \mathbf{b} = \mathbf{0}$ pour tout $\mathbf{x}^*$.

1.5 Exercice 5.5

Énoncé : Utiliser la définition (5.38) avec (5.30) et (5.31) pour dériver le résultat (5.39) pour le score F.

Solution détaillée :
Rappelons les définitions :

$$\text{Précision} = \frac{N_{\mathrm{TP}}}{N_{\mathrm{TP}} + N_{\mathrm{FP}}}, \qquad \text{Rappel} = \frac{N_{\mathrm{TP}}}{N_{\mathrm{TP}} + N_{\mathrm{FN}}}.$$

Alors

$$\text{Précision} \times \text{Rappel} = \frac{N_{\mathrm{TP}}^2}{(N_{\mathrm{TP}} + N_{\mathrm{FP}})(N_{\mathrm{TP}} + N_{\mathrm{FN}})}.$$

D'autre part,

$$\text{Précision+Rappel} = \frac{N_{\mathrm{TP}}}{N_{\mathrm{TP}} + N_{\mathrm{FP}}} + \frac{N_{\mathrm{TP}}}{N_{\mathrm{TP}} + N_{\mathrm{FN}}} = \frac{N_{\mathrm{TP}}(N_{\mathrm{TP}} + N_{\mathrm{FN}}) + N_{\mathrm{TP}}(N_{\mathrm{TP}} + N_{\mathrm{FP}})}{(N_{\mathrm{TP}} + N_{\mathrm{FP}})(N_{\mathrm{TP}} + N_{\mathrm{FN}})}.$$

Le score F est défini par la moyenne harmonique :

$$F = \frac{2 \times \text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}.$$

En substituant les expressions ci-dessus :

$$F = \frac{2 \cdot \frac{N_{\mathrm{TP}}^2}{(N_{\mathrm{TP}}+N_{\mathrm{FP}})(N_{\mathrm{TP}}+N_{\mathrm{FN}})}}{\frac{N_{\mathrm{TP}}(2N_{\mathrm{TP}}+N_{\mathrm{FN}}+N_{\mathrm{FP}})}{(N_{\mathrm{TP}}+N_{\mathrm{FP}})(N_{\mathrm{TP}}+N_{\mathrm{FN}})}} = \frac{2N_{\mathrm{TP}}}{2N_{\mathrm{TP}} + N_{\mathrm{FP}} + N_{\mathrm{FN}}}.$$

1.6 Exercice 5.6

Énoncé : Soit deux nombres non négatifs a et b. Montrer que si $a \leq b$, alors $a \leq (ab)^{1/2}$. Utiliser ce résultat pour montrer que si les régions de décision d'un problème de classification à deux classes sont choisies pour minimiser la probabilité d'erreur, cette probabilité satisfait :

$$p(\text{erreur}) \leq \int \left\{p(\mathbf{x}, \mathcal{C}_1)p(\mathbf{x}, \mathcal{C}_2)\right\}^{1/2} \mathrm{d}\mathbf{x}.$$

Solution détaillée :
Puisque la fonction racine carrée est monotone croissante sur $\mathbb{R}^+$, de $a \leq b$ on tire $\sqrt{a} \leq \sqrt{b}$. En multipliant par $\sqrt{a} \geq 0$, on obtient $a \leq \sqrt{ab}$.

La probabilité d'erreur s'écrit :

$$p(\text{erreur}) = \int_{\mathcal{R}_1} p(\mathbf{x}, \mathcal{C}_2)\mathrm{d}\mathbf{x} + \int_{\mathcal{R}_2} p(\mathbf{x}, \mathcal{C}_1)\mathrm{d}\mathbf{x}.$$

Les régions $\mathcal{R}_1$ et $\mathcal{R}_2$ sont choisies pour minimiser cette probabilité, donc on a $p(\mathcal{C}_2|\mathbf{x}) \leq p(\mathcal{C}_1|\mathbf{x})$ dans $\mathcal{R}_1$ et l'inégalité inverse dans $\mathcal{R}_2$. En utilisant le résultat préliminaire avec $a = p(\mathbf{x}, \mathcal{C}_2)$ et $b = p(\mathbf{x}, \mathcal{C}_1)$ dans $\mathcal{R}_1$ (où $a \leq b$), on a $p(\mathbf{x}, \mathcal{C}_2) \leq \{p(\mathbf{x}, \mathcal{C}_1)p(\mathbf{x}, \mathcal{C}_2)\}^{1/2}$. De même, dans $\mathcal{R}_2$, $p(\mathbf{x}, \mathcal{C}_1) \leq \{p(\mathbf{x}, \mathcal{C}_1)p(\mathbf{x}, \mathcal{C}_2)\}^{1/2}$. En intégrant sur chaque région et en sommant, on obtient l'inégalité désirée, les deux intégrales ayant le même intégrande.

1.7 Exercice 5.7

Énoncé : Étant donné une matrice de perte L_{kj}, le risque espéré est minimisé en choisissant pour chaque $\mathbf{x}$ la classe qui minimise $\sum_k L_{kj}p(\mathcal{C}_k|\mathbf{x})$. Vérifier que lorsque la matrice de perte est $L_{kj} = 1 - \delta_{kj}$ (perte unitaire pour toute erreur, perte nulle pour une classification correcte), cette règle revient à choisir la classe de plus grande probabilité a posteriori.

Solution détaillée :
Avec $L_{kj} = 1 - \delta_{kj}$, on a $\sum_k L_{kj}p(\mathcal{C}_k|\mathbf{x}) = \sum_k (1 - \delta_{kj})p(\mathcal{C}_k|\mathbf{x}) = \sum_k p(\mathcal{C}_k|\mathbf{x}) - p(\mathcal{C}_j|\mathbf{x}) = 1 - p(\mathcal{C}_j|\mathbf{x})$ car les probabilités a posteriori somment à 1. Minimiser cette quantité par rapport à j équivaut donc à maximiser $p(\mathcal{C}_j|\mathbf{x})$. On retrouve bien la règle du maximum a posteriori.

1.8 Exercice 5.8

Énoncé : Établir le critère de minimisation de la perte espérée pour une matrice de perte générale et des probabilités a priori générales.

Solution détaillée :
D'après (5.23), pour chaque $\mathbf{x}$, on doit choisir la classe j qui minimise $\sum_k L_{kj}p(\mathcal{C}_k|\mathbf{x})$. En utilisant la règle de Bayes, $p(\mathcal{C}_k|\mathbf{x}) = \frac{p(\mathbf{x}|\mathcal{C}_k)p(\mathcal{C}_k)}{p(\mathbf{x})}$. Le dénominateur $p(\mathbf{x})$ est commun à tous les k pour un $\mathbf{x}$ fixé, donc le critère équivaut à minimiser $\sum_k L_{kj}p(\mathbf{x}|\mathcal{C}_k)p(\mathcal{C}_k)$. Ainsi, la décision optimale dépend à la fois des probabilités a priori et des éléments de la matrice de perte.

1.9 Exercice 5.9

Énoncé : Considérons la moyenne des probabilités a posteriori sur un ensemble de N points : $\frac{1}{N}\sum_{n=1}^{N} p(\mathcal{C}_k|\mathbf{x}_n)$. En prenant la limite $N \to \infty$, montrer que cette quantité tend vers la probabilité a priori $p(\mathcal{C}_k)$.

Solution détaillée :
La somme est une approximation par échantillonnage de l'espérance. Quand $N \to \infty$, on a :

$$\frac{1}{N}\sum_{n=1}^{N} p(\mathcal{C}_k|\mathbf{x}_n) \longrightarrow \mathbb{E}_{\mathbf{x}}[p(\mathcal{C}_k|\mathbf{x})] = \int p(\mathcal{C}_k|\mathbf{x})p(\mathbf{x})\mathrm{d}\mathbf{x}.$$

Or $p(\mathcal{C}_k|\mathbf{x})p(\mathbf{x}) = p(\mathbf{x}, \mathcal{C}_k)$. En intégrant sur $\mathbf{x}$, on obtient $p(\mathcal{C}_k)$ par marginalisation.

1.10 Exercice 5.10

Énoncé : Dans un problème de classification, la perte encourue lorsqu'un vecteur d'entrée de la classe $\mathcal{C}_k$ est classé en $\mathcal{C}_j$ est L_{kj} et la perte pour l'option de rejet est λ. Trouver le critère de décision qui minimise la perte espérée. Vérifier qu'il se réduit au critère de rejet standard lorsque la matrice de perte est $L_{kj} = 1 - I_{kj}$. Quelle est la relation entre λ et le seuil de rejet θ ?

Solution détaillée :

Pour un $\mathbf{x}$ donné, la perte espérée si l'on choisit la classe j est $\sum_k L_{kj} p(\mathcal{C}_k|\mathbf{x})$. Si l'on choisit le rejet, la perte est λ. On choisit donc la classe j qui minimise $\sum_k L_{kj} p(\mathcal{C}_k|\mathbf{x})$ si ce minimum est inférieur à λ, sinon on rejette.

Avec $L_{kj} = 1 - I_{kj}$, on a $\sum_k L_{kj} p(\mathcal{C}_k|\mathbf{x}) = 1 - p(\mathcal{C}_j|\mathbf{x})$. Le minimum sur j de cette quantité est $1 - \max_j p(\mathcal{C}_j|\mathbf{x})$. On rejette donc si $1 - \max_j p(\mathcal{C}_j|\mathbf{x}) \geq \lambda$, c'est-à-dire si $\max_j p(\mathcal{C}_j|\mathbf{x}) \leq 1 - \lambda$. Le critère de rejet standard est de rejeter si la plus grande probabilité a posteriori est inférieure à un seuil θ. On a donc équivalence avec $\theta = 1 - \lambda$.

1.11 Exercice 5.11

Énoncé : Montrer que la fonction sigmoïde logistique $\sigma(a) = 1/(1+e^{-a})$ satisfait $\sigma(-a) = 1 - \sigma(a)$ et que son inverse est $\sigma^{-1}(y) = \ln(y/(1-y))$.

Solution détaillée :

$$1 - \sigma(a) = 1 - \frac{1}{1+e^{-a}} = \frac{1+e^{-a}-1}{1+e^{-a}} = \frac{e^{-a}}{1+e^{-a}} = \frac{1}{e^{a}+1} = \sigma(-a).$$

Pour l'inverse, on pose $y = \sigma(a) = \frac{1}{1+e^{-a}}$. Alors $1 - y = \frac{e^{-a}}{1+e^{-a}}$, d'où $\frac{y}{1-y} = e^{a}$ et donc $a = \ln \frac{y}{1-y}$.

1.12 Exercice 5.12

Énoncé : En utilisant (5.40) et (5.41), établir le résultat (5.48) pour la probabilité a posteriori dans le modèle génératif à deux classes avec des densités gaussiennes, et vérifier les résultats (5.49) et (5.50) pour les paramètres $\mathbf{w}$ et w_0.

Solution détaillée :

On a $p(\mathcal{C}_1|\mathbf{x}) = \sigma(a)$ avec $a = \ln \frac{p(\mathbf{x}|\mathcal{C}_1)p(\mathcal{C}_1)}{p(\mathbf{x}|\mathcal{C}_2)p(\mathcal{C}_2)}$. En substituant les densités gaussiennes avec covariance commune $\boldsymbol{\Sigma}$:

$$p(\mathbf{x}|\mathcal{C}_k) = \frac{1}{(2\pi)^{D/2}|\boldsymbol{\Sigma}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x}-\mu_k)^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}(\mathbf{x}-\mu_k)\right).$$

Le rapport des densités devient :

$$\frac{p(\mathbf{x}|\mathcal{C}_1)}{p(\mathbf{x}|\mathcal{C}_2)} = \exp\left(-\frac{1}{2}(\mathbf{x}-\mu_1)^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}(\mathbf{x}-\mu_1) + \frac{1}{2}(\mathbf{x}-\mu_2)^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}(\mathbf{x}-\mu_2)\right).$$

En développant les termes quadratiques, les termes $\mathbf{x}^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}\mathbf{x}$ s'annulent, et il reste :

$$-\frac{1}{2}\left(-2\mu_1^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}\mathbf{x} + \mu_1^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}\mu_1 + 2\mu_2^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}\mathbf{x} - \mu_2^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}\mu_2\right) = (\mu_1-\mu_2)^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}\mathbf{x} - \frac{1}{2}\left(\mu_1^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}\mu_1 - \mu_2^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}\mu\right.$$

En ajoutant le logarithme des probabilités a priori, on obtient :

$$a = (\mu_1-\mu_2)^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}\mathbf{x} - \frac{1}{2}\mu_1^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}\mu_1 + \frac{1}{2}\mu_2^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}\mu_2 + \ln\frac{p(\mathcal{C}_1)}{p(\mathcal{C}_2)}.$$

On reconnaît la forme linéaire $a = \mathbf{w}^{\mathrm{T}}\mathbf{x} + w_0$ avec

$$\mathbf{w} = \boldsymbol{\Sigma}^{-1}(\mu_1-\mu_2), \qquad w_0 = -\frac{1}{2}\mu_1^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}\mu_1 + \frac{1}{2}\mu_2^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}\mu_2 + \ln\frac{p(\mathcal{C}_1)}{p(\mathcal{C}_2)}.$$

1.13 Exercice 5.13

Énoncé : Considérons un modèle génératif à K classes défini par les probabilités a priori $p(\mathcal{C}_k) = \pi_k$ et des densités de classe conditionnelles générales $p(\boldsymbol{\phi}|\mathcal{C}_k)$, où $\boldsymbol{\phi}$ est le vecteur de caractéristiques. On dispose d'un ensemble d'apprentissage $\{\boldsymbol{\phi}_n, \mathbf{t}_n\}$ avec $n = 1, \ldots, N$, où $\mathbf{t}_n$ est un vecteur binaire utilisant le codage 1-parmi-K. En supposant les points indépendants, montrer que la solution du maximum de vraisemblance pour les probabilités a priori est $\pi_k = N_k/N$ où N_k est le nombre de points de la classe $\mathcal{C}_k$.

Solution détaillée :

La vraisemblance s'écrit :

$$p(\{\boldsymbol{\phi}_n, \mathbf{t}_n\}|\{\pi_k\}) = \prod_{n=1}^{N}\prod_{k=1}^{K}\left(p(\boldsymbol{\phi}_n|\mathcal{C}_k)\pi_k\right)^{t_{nk}}.$$

En prenant le logarithme :

$$\ln p = \sum_{n=1}^{N}\sum_{k=1}^{K} t_{nk}\left(\ln p(\boldsymbol{\phi}_n|\mathcal{C}_k) + \ln \pi_k\right).$$

Pour maximiser sous la contrainte $\sum_k \pi_k = 1$, on introduit un multiplicateur de Lagrange λ et on maximise :

$$\sum_{n=1}^{N}\sum_{k=1}^{K} t_{nk}\ln\pi_k + \lambda\left(\sum_k \pi_k - 1\right) + \text{termes indépendants de } \pi_k.$$

La dérivée par rapport à π_k donne :

$$\sum_{n=1}^{N}\frac{t_{nk}}{\pi_k} + \lambda = 0 \quad\Longrightarrow\quad -\lambda\pi_k = \sum_{n=1}^{N} t_{nk} = N_k.$$

En sommant sur k : $-\lambda\sum_k \pi_k = \sum_k N_k = N$, donc $-\lambda = N$. On en déduit $\pi_k = N_k/N$.

1.14 Exercice 5.14

Énoncé : Dans le modèle de l'exercice 5.13, supposons maintenant que les densités de classe sont gaussiennes avec une matrice de covariance commune : $p(\boldsymbol{\phi}|\mathcal{C}_k) = \mathcal{N}(\boldsymbol{\phi}|\mu_k, \boldsymbol{\Sigma})$. Montrer que la solution du maximum de vraisemblance pour la moyenne de la classe $\mathcal{C}_k$ est $\mu_k = \frac{1}{N_k}\sum_n t_{nk}\boldsymbol{\phi}_n$. Montrer de même que pour la matrice de covariance partagée, on a $\boldsymbol{\Sigma} = \sum_{k=1}^{K}\frac{N_k}{N}\mathbf{S}_k$ avec $\mathbf{S}_k = \frac{1}{N_k}\sum_n t_{nk}(\boldsymbol{\phi}_n - \mu_k)(\boldsymbol{\phi}_n - \mu_k)^{\mathrm{T}}$.

Solution détaillée :

En substituant la densité gaussienne dans la log-vraisemblance (en ne gardant que les termes dépendant de μ_k et $\boldsymbol{\Sigma}$), on obtient :

$$\ln p = -\frac{1}{2}\sum_{n=1}^{N}\sum_{k=1}^{K} t_{nk}\left\{\ln|\boldsymbol{\Sigma}| + (\boldsymbol{\phi}_n - \mu_k)^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}(\boldsymbol{\phi}_n - \mu_k)\right\} + \text{const.}$$

La dérivée par rapport à μ_k (en utilisant (A.19)) donne :

$$\sum_{n=1}^{N} t_{nk}\boldsymbol{\Sigma}^{-1}(\boldsymbol{\phi}_n - \mu_k) = 0 \quad\Longrightarrow\quad \mu_k = \frac{\sum_n t_{nk}\boldsymbol{\phi}_n}{\sum_n t_{nk}} = \frac{1}{N_k}\sum_{n\in\mathcal{C}_k}\boldsymbol{\phi}_n.$$

Pour $\boldsymbol{\Sigma}$, on réécrit la log-vraisemblance en utilisant la trace :

$$-\frac{1}{2}\sum_{n,k} t_{nk}\left(\ln|\boldsymbol{\Sigma}| + \mathrm{Tr}\left[\boldsymbol{\Sigma}^{-1}(\boldsymbol{\phi}_n - \mu_k)(\boldsymbol{\phi}_n - \mu_k)^{\mathrm{T}}\right]\right).$$

En dérivant par rapport à $\boldsymbol{\Sigma}^{-1}$ (en utilisant (A.24) et (A.28)), on obtient :

$$\frac{1}{2}\sum_{n,k} t_{nk}\left(\boldsymbol{\Sigma} - (\boldsymbol{\phi}_n - \mu_k)(\boldsymbol{\phi}_n - \mu_k)^{\mathrm{T}}\right) = 0.$$

D'où $\boldsymbol{\Sigma} = \frac{1}{N}\sum_{n,k} t_{nk}(\boldsymbol{\phi}_n - \mu_k)(\boldsymbol{\phi}_n - \mu_k)^{\mathrm{T}}$. En séparant par classe, $\sum_n t_{nk}(\boldsymbol{\phi}_n - \mu_k)(\boldsymbol{\phi}_n - \mu_k)^{\mathrm{T}} = N_k\mathbf{S}_k$. Ainsi $\boldsymbol{\Sigma} = \sum_k \frac{N_k}{N}\mathbf{S}_k$.

1.15 Exercice 5.15

Énoncé : Établir la solution du maximum de vraisemblance pour les paramètres $\{\mu_{ki}\}$ du classifieur naïf de Bayes avec caractéristiques binaires décrit en Section 5.3.3.

Solution détaillée :
Pour une classe $\mathcal{C}_k$, la vraisemblance des données (caractéristiques binaires) est :

$$\ln p(\mathcal{D}|\mathcal{C}_k) = \sum_{n=1}^{N}\sum_{i=1}^{D}\left(x_{ni}\ln\mu_{ki} + (1-x_{ni})\ln(1-\mu_{ki})\right).$$

En dérivant par rapport à μ_{ki} et en annulant :

$$0 = \sum_{n=1}^{N}\left(\frac{x_{ni}}{\mu_{ki}} - \frac{1-x_{ni}}{1-\mu_{ki}}\right).$$

En réarrangeant :

$$\frac{1}{\mu_{ki}}\sum_n x_{ni} = \frac{1}{1-\mu_{ki}}\sum_n (1-x_{ni}).$$

Soit N_k le nombre de points de la classe k. Alors $\sum_n x_{ni}$ est le nombre de points de cette classe pour lesquels la i-ème caractéristique vaut 1, notons-le N_{ki}. On a donc :

$$\frac{N_{ki}}{\mu_{ki}} = \frac{N_k - N_{ki}}{1-\mu_{ki}} \quad\Longrightarrow\quad \mu_{ki} = \frac{N_{ki}}{N_k}.$$

C'est bien la proportion de 1 dans la classe pour cette caractéristique.

1.16 Exercice 5.16

Énoncé : Considérons un problème à K classes avec un vecteur de caractéristiques $\boldsymbol{\phi}$ à M composantes, chacune pouvant prendre L états discrets, représentés par un codage 1-parmi-L. On suppose qu'à l'intérieur de chaque classe $\mathcal{C}_k$, les M composantes sont indépendantes (naïf de Bayes). Montrer que les quantités a_k données par (5.46) sont des fonctions linéaires des composantes de $\boldsymbol{\phi}$.

Solution détaillée :
La densité conditionnelle s'écrit, en factorisant :

$$p(\boldsymbol{\phi}|\mathcal{C}_k) = \prod_{m=1}^{M}\prod_{l=1}^{L}\mu_{kml}^{\phi_{ml}},$$

où ϕ_{ml} vaut 1 si la m-ième composante est dans l'état l, et 0 sinon. Alors

$$a_k = \ln p(\boldsymbol{\phi}|\mathcal{C}_k) + \ln p(\mathcal{C}_k) = \ln p(\mathcal{C}_k) + \sum_{m=1}^{M}\sum_{l=1}^{L}\phi_{ml}\ln\mu_{kml}.$$

C'est bien une combinaison linéaire des variables ϕ_{ml}, donc linéaire en $\boldsymbol{\phi}$.

1.17 Exercice 5.17

Énoncé : Établir la solution du maximum de vraisemblance pour les paramètres du classifieur naïf de Bayes décrit dans l'exercice 5.16.

Solution détaillée :
Pour une classe $\mathcal{C}_k$, la log-vraisemblance est :

$$\ln p(\mathcal{D}|\mathcal{C}_k) = \sum_{n=1}^{N}\sum_{m=1}^{M}\sum_{l=1}^{L}\phi_{nml}\ln\mu_{kml}.$$

Sous la contrainte $\sum_l \mu_{kml} = 1$ pour chaque m, on introduit des multiplicateurs de Lagrange λ_{km} et on maximise :

$$\sum_{n=1}^{N}\sum_{m,l}\phi_{nml}\ln\mu_{kml} + \sum_m \lambda_{km}\left(\sum_l \mu_{kml} - 1\right).$$

La dérivée par rapport à μ_{kml} donne :

$$\sum_{n=1}^{N}\frac{\phi_{nml}}{\mu_{kml}} + \lambda_{km} = 0 \quad\Longrightarrow\quad \mu_{kml} = -\frac{1}{\lambda_{km}}\sum_n \phi_{nml}.$$

En utilisant la contrainte, $\sum_l \mu_{kml} = -\frac{1}{\lambda_{km}}\sum_n\sum_l \phi_{nml} = 1$, donc $\lambda_{km} = -\sum_n\sum_l \phi_{nml}$. En reportant, on obtient :

$$\mu_{kml} = \frac{\sum_n \phi_{nml}}{\sum_n\sum_{l'}\phi_{nml'}}.$$

C'est la proportion, pour la classe k, d'occurrences de l'état l pour la composante m.

1.18 Exercice 5.18

Énoncé : Vérifier la relation (5.72) pour la dérivée de la fonction sigmoïde logistique.

Solution détaillée :
Soit $\sigma(a) = 1/(1+e^{-a})$. Alors

$$\frac{d\sigma}{da} = \frac{e^{-a}}{(1+e^{-a})^2} = \frac{1}{1+e^{-a}}\cdot\frac{e^{-a}}{1+e^{-a}} = \sigma(a)\left(1 - \frac{1}{1+e^{-a}}\right) = \sigma(a)(1-\sigma(a)).$$

1.19 Exercice 5.19

Énoncé : En utilisant le résultat (5.72), montrer que la dérivée de la fonction d'erreur (5.74) pour la régression logistique est donnée par (5.75).

Solution détaillée :
L'erreur est $E(\mathbf{w}) = -\sum_{n=1}^{N}(t_n\ln y_n + (1-t_n)\ln(1-y_n))$ avec $y_n = \sigma(\mathbf{w}^{\mathrm{T}}\boldsymbol{\phi}_n)$. Calculons d'abord $\frac{\partial E}{\partial y_n}$:

$$\frac{\partial E}{\partial y_n} = -\frac{t_n}{y_n} + \frac{1-t_n}{1-y_n} = \frac{-t_n(1-y_n) + (1-t_n)y_n}{y_n(1-y_n)} = \frac{y_n - t_n}{y_n(1-y_n)}.$$

Puis $\frac{\partial y_n}{\partial a_n} = y_n(1-y_n)$ d'après (5.72). Enfin $\nabla_{\mathbf{w}} a_n = \boldsymbol{\phi}_n$. Par la règle de chaîne,

$$\nabla_{\mathbf{w}} E = \sum_{n=1}^{N}\frac{\partial E}{\partial y_n}\frac{\partial y_n}{\partial a_n}\nabla_{\mathbf{w}} a_n = \sum_{n=1}^{N}\frac{y_n - t_n}{y_n(1-y_n)}\cdot y_n(1-y_n)\cdot\boldsymbol{\phi}_n = \sum_{n=1}^{N}(y_n - t_n)\boldsymbol{\phi}_n.$$

1.20 Exercice 5.20

Énoncé : Montrer que pour un ensemble de données linéairement séparable, la solution du maximum de vraisemblance pour la régression logistique est obtenue en trouvant un vecteur $\mathbf{w}$ dont la frontière de décision $\mathbf{w}^{\mathrm{T}}\boldsymbol{\phi}(\mathbf{x}) = 0$ sépare les classes, puis en faisant tendre la norme de $\mathbf{w}$ vers l'infini.

Solution détaillée :
Si les données sont séparables, il existe un hyperplan qui sépare parfaitement les deux classes. Dans la régression logistique, la vraisemblance est maximisée quand chaque point est assigné à la classe correcte avec une probabilité proche de 1. La fonction sigmoïde tend vers 1 quand son argument tend vers $+\infty$ et vers 0 quand il tend vers $-\infty$. Ainsi, pour que $y_n = \sigma(\mathbf{w}^{\mathrm{T}}\boldsymbol{\phi}_n)$ soit proche de 1 pour les points de classe 1 et proche de 0 pour ceux de classe 2, il faut que $\mathbf{w}^{\mathrm{T}}\boldsymbol{\phi}_n$ soit très grand positif pour la classe 1 et très grand négatif pour la classe 2. Cela est possible si la direction de $\mathbf{w}$ est celle de la normale à l'hyperplan séparateur, et en multipliant $\mathbf{w}$ par un facteur d'échelle tendant vers l'infini. La vraisemblance tend alors vers 1, et l'erreur croisée tend vers 0. Toute solution avec un $\mathbf{w}$ de norme finie donne une vraisemblance strictement inférieure.

1.21 Exercice 5.21

Énoncé : Montrer que les dérivées de la fonction softmax (5.76) avec $a_k = \mathbf{w}_k^{\mathrm{T}}\boldsymbol{\phi}$ sont données par (5.78).

Solution détaillée :
Soit $y_k = \frac{e^{a_k}}{\sum_j e^{a_j}}$. Alors

$$\frac{\partial y_k}{\partial a_j} = \frac{e^{a_k}\delta_{kj}\sum_i e^{a_i} - e^{a_k}e^{a_j}}{(\sum_i e^{a_i})^2} = y_k\delta_{kj} - y_k y_j.$$

On a donc $\frac{\partial y_k}{\partial a_j} = y_k(I_{kj} - y_j)$.

1.22 Exercice 5.22

Énoncé : En utilisant (5.78), montrer que les gradients de l'erreur de type entropie croisée (5.80) sont donnés par (5.81).
Solution détaillée :
L'erreur est $E = -\sum_{n=1}^{N}\sum_{k=1}^{K} t_{nk}\ln y_{nk}$. Calculons $\frac{\partial E}{\partial a_{nj}}$ en utilisant la règle de chaîne :

$$\frac{\partial E}{\partial a_{nj}} = \sum_{k=1}^{K}\frac{\partial E}{\partial y_{nk}}\frac{\partial y_{nk}}{\partial a_{nj}} = \sum_{k=1}^{K}\left(-\frac{t_{nk}}{y_{nk}}\right)\cdot y_{nk}(I_{kj} - y_{nj}) = -\sum_{k=1}^{K} t_{nk}I_{kj} + \sum_{k=1}^{K} t_{nk}y_{nj}.$$

Puisque $\sum_k t_{nk} = 1$ (un seul 1 dans le codage 1-parmi-K), on a $\sum_k t_{nk}I_{kj} = t_{nj}$ et $\sum_k t_{nk}y_{nj} = y_{nj}$. Donc $\frac{\partial E}{\partial a_{nj}} = y_{nj} - t_{nj}$. Finalement,

$$\nabla_{\mathbf{w}_j} E = \sum_{n=1}^{N}\frac{\partial E}{\partial a_{nj}}\nabla_{\mathbf{w}_j} a_{nj} = \sum_{n=1}^{N}(y_{nj} - t_{nj})\boldsymbol{\phi}_n.$$

1.23 Exercice 5.23

Énoncé : Montrer que la fonction probit (5.86) et la fonction erf (5.87) sont reliées par (5.88).
Solution détaillée :
La fonction probit est $\Phi(a) = \int_{-\infty}^{a}\mathcal{N}(\theta|0,1)\mathrm{d}\theta$. Pour $a \geq 0$, on peut écrire :

$$\Phi(a) = \int_{-\infty}^{0}\mathcal{N}(\theta|0,1)\mathrm{d}\theta + \int_{0}^{a}\frac{1}{\sqrt{2\pi}}e^{-\theta^2/2}\mathrm{d}\theta = \frac{1}{2} + \frac{1}{\sqrt{2\pi}}\int_{0}^{a/\sqrt{2}} e^{-u^2}\sqrt{2}\mathrm{d}u,$$

en posant $u = \theta/\sqrt{2}$. L'intégrale $\frac{2}{\sqrt{\pi}}\int_0^z e^{-u^2}\mathrm{d}u = \mathrm{erf}(z)$. Donc

$$\Phi(a) = \frac{1}{2} + \frac{1}{\sqrt{2\pi}}\sqrt{2}\cdot\frac{\sqrt{\pi}}{2}\mathrm{erf}\left(\frac{a}{\sqrt{2}}\right) = \frac{1}{2}\left(1 + \mathrm{erf}\left(\frac{a}{\sqrt{2}}\right)\right).$$

Pour $a < 0$, on utilise la symétrie $\Phi(a) = 1 - \Phi(-a)$.

1.24 Exercice 5.24

Énoncé : On souhaite approcher la sigmoïde logistique $\sigma(a)$ par une fonction probit mise à l'échelle $\Phi(\lambda a)$. Montrer que si λ est choisi de sorte que les dérivées des deux fonctions soient égales en $a = 0$, alors $\lambda^2 = \pi/8$.
Solution détaillée :
La dérivée de σ en 0 est $\sigma'(0) = \sigma(0)(1 - \sigma(0)) = \frac{1}{2}\cdot\frac{1}{2} = \frac{1}{4}$. La dérivée de $\Phi(\lambda a)$ est $\lambda\mathcal{N}(0|0,1) = \lambda\frac{1}{\sqrt{2\pi}}$. En égalant :

$$\frac{1}{4} = \frac{\lambda}{\sqrt{2\pi}} \implies \lambda = \frac{\sqrt{2\pi}}{4} \implies \lambda^2 = \frac{2\pi}{16} = \frac{\pi}{8}.$$